UNIVERSIDAD TECNOLÓGICA NACIONAL · DIPLOMATURA

TRABAJO FINAL INTEGRADOR

Predicción de abandono bancario

y priorización de retención

Comparación de cuatro modelos de clasificación y propuesta de priorización comercial, a partir de la preentrega aprobada del Grupo 53.

10.000
clientes analizados

4
modelos comparados

63,4%
de abandonos en el top 20%

GRUPO 53 Julian Appella · Cintia Opaso · Leonardo Caporossi · Mariangeles Fontela

OCTUBRE 2026 · UNIDAD 9

Una pregunta concreta para Retención

La preentrega del 21/09/2026 (90/100) fue considerada viable. Esta versión desarrolla la validación y el impacto comercial solicitados por el docente.

SITUACIÓN DEL BANCO HIPOTÉTICO

2.037 de 10.000 clientes presentan **Exited = 1** (abandono observado). La tasa base es **20,37%**. Con recursos limitados, contactar a toda la cartera no es una estrategia operativa realista.

Pregunta de negocio: si solo contactamos al **20% con mayor riesgo**, ¿qué proporción de los abandonos observados podemos identificar?

20,37%

tasa histórica de abandono

20%

capacidad de contactos del ejercicio

DE LA PREENTREGA AL TRABAJO FINAL

01
Validación
80/20 estratificado + CV

02
Métricas
Precision, Recall, F1, AP

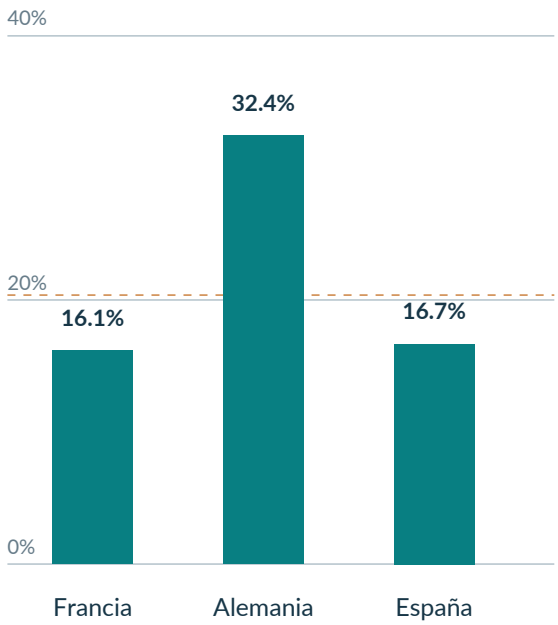
03
Selección
Comparación de 4 modelos

04
Negocio
Captura al 20% priorizado

¿Qué muestran los datos?

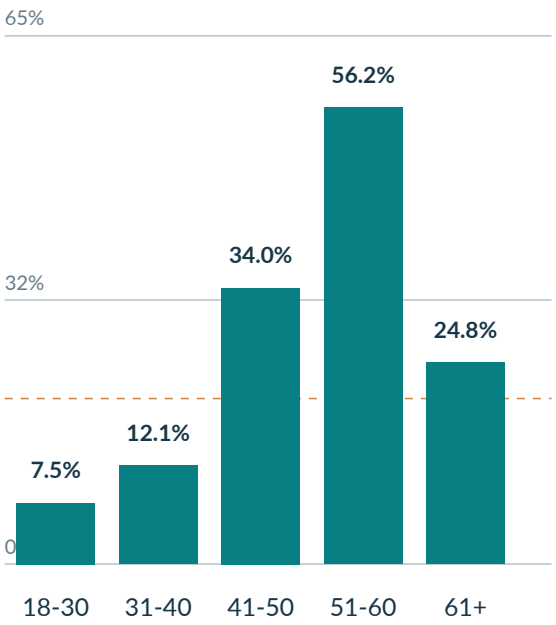
El conjunto Churn Modeling.csv contiene 10.000 registros y 14 columnas, con clientes de Francia, Alemania y España.

Abandono por país



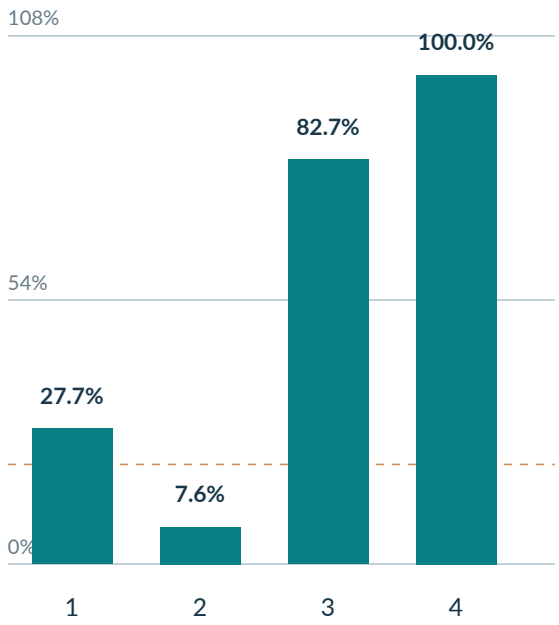
Alemania presenta 32,4% de abandono.

Abandono por edad



El tramo 51-60 años alcanza 56,2%.

Abandono por productos



Los grupos con 3-4 productos son pequeños.

Lectura: edad, país y cantidad de productos muestran asociaciones con el abandono. Son hallazgos exploratorios; **no prueban causalidad** ni justifican tratar de forma desigual a un segmento.

De un CSV a variables comparables

Conservamos las decisiones de limpieza de la preentrega y formalizamos transformaciones reproducibles dentro de cada partición de entrenamiento.

10.000
filas

14
columnas originales

0
nulos y duplicados

DECISIONES SOBRE LOS DATOS

Control	Hallazgo	Decisión
Identificadores	RowNumber, CustomerId, Surname	No se utilizan como predictores
Balance igual a cero	3.617 clientes (36,17%)	Se conserva; se agrega BalanceZero
Edad extrema	Máximo de 92 años	Se conserva al no detectar error
Categorías y escalas	Geography, Gender y numéricas	One-Hot + escalado en Pipeline

Regla para evitar fuga de datos: las transformaciones se aprenden solo con entrenamiento y se vuelven a ajustar dentro de cada fold. **Exited** queda exclusivamente como variable objetivo; **EstimatedSalary** se mantiene, aunque la preentrega proponía revisar su exclusión.

Cómo comprobamos que los modelos funcionan

El esquema experimental responde a la observación principal del profesor: validar, medir y seleccionar el modelo con un criterio común.

PARTICIÓN ESTRATIFICADA: SE CONSERVA LA PROPORCIÓN DE ABANDONO



Test reservado: 407 abandonos reales de 2.000 clientes.

1 · Cinco folds

Validación cruzada estratificada en el 80% de entrenamiento.

2 · Umbral por F1

Para cada modelo, el corte se define con predicciones OOF de train.

3 · Elegir ganador

Mayor F1 OOF; AP como criterio de desempate.

QUÉ SE CONSERVA DE LA PREENTREGA

Los cuatro algoritmos fueron definidos a partir de trabajos técnicos anteriores. Allí se utilizaron búsquedas **GridSearchCV** para explorar parámetros; en esta entrega se documentan como **antecedente**, sin repetirlas. La nueva validación cruzada **sí se ejecuta**. El F1 OOF puede ser algo optimista por la elección del umbral sobre esos mismos scores.

¿Cuál elegimos y por qué?

Comparamos las mismas cuatro familias propuestas en la preentrega, con el mismo criterio técnico: F1 de la clase Exited = 1.

Modelo	F1 CV (OOF)	AP / PR-AUC	Captura@20%	Umbral
LightGBM	**0,628**	**0,693**	**61,8%**	**0,314**
SVM RBF	0,599	0,632	58,3%	0,087
Árbol de decisión	0,585	0,626	57,9%	0,395
Regresión logística	0,500	0,452	47,0%	0,544

DECISIÓN TOMADA ANTES DE EVALUAR EL TEST

LightGBM obtiene el mayor F1 en validación cruzada (**0,628**) y también la mayor Average Precision (**0,693**). Por eso se lo selecciona. F1 equilibra Precision y Recall; AP indica la calidad del ordenamiento a través de distintos umbrales. El conjunto test **no se utiliza para cambiar esta elección**.

¿Qué pasó en los 2.000 clientes de test?

Las configuraciones y umbrales se fijaron con entrenamiento. El conjunto reservado permite contrastar las métricas fuera de la selección.

Modelo	Precision	Recall	F1	AP / PR-AUC	ROC-AUC
LightGBM	**0,643**	**0,641**	**0,642**	**0,712**	**0,867**
SVM RBF	0,506	0,727	0,597	0,643	0,847
Árbol de decisión	0,581	0,570	0,576	0,632	0,823
Regresión logística	0,415	0,641	0,504	0,468	0,777

MATRIZ DE CONFUSIÓN DE LIGHTGBM (UMBRAL = 0,314)

1.448 Permanece / correcto	**145** Falsas alarmas
146 Abandonos no detectados	**261** Abandonos detectados

Lectura del resultado: el modelo identifica **261** abandonos con su umbral de clasificación. Este número **no es** el mismo que la captura de **258** abandonos al imponer exactamente 400 contactos. Son dos decisiones diferentes.

¿Qué logramos contactando solo al 20%?

Evaluación retrospectiva sobre los 2.000 clientes reservados para test, siguiendo el escenario solicitado por el profesor.

400

clientes seleccionados (20%)

258

abandonos identificados

63,4%

Recall@20%: cobertura de abandonos

COBERTURA DEL ABANDONO OBSERVADO



3,17 veces

la captura esperada por selección aleatoria, que sería aproximadamente el **20%** de los abandonos.

64,5%

Precision@20%: entre los **400 contactos**, **258** corresponden a clientes que abandonaron en los registros.

Qué aprendimos y qué no podemos afirmar

Los resultados sirven para evaluar un ranking en el CSV disponible; no validan todavía su desempeño en una cartera futura.

VARIABLES QUE MÁS APORTAN AL RANKING



Importancia por permutación en test: mide cuánto se reduce AP al alterar una variable; no implica causalidad.

SENSIBILIDAD: CLIENTES CON 3-4 PRODUCTOS

Al excluir **solo para el diagnóstico** ese grupo del test, quedan **1.931 clientes**. El modelo no se reentrena.

F1	0,642 → 0,588
AP	0,712 → 0,629

RIESGOS QUE LIMITAN UNA APLICACIÓN REAL

Sin dimensión temporal

No hay fechas ni se puede afirmar abandono a 12 meses.

Datos no representativos

Origen primario, licencia y validez externa no acreditados.

Sesgo y privacidad

Auditar género, país y edad; proteger información personal.

Del análisis a una decisión informada

El estudio sostiene la viabilidad del enfoque de la preentrega y responde a la devolución docente con una evaluación reproducible.

Conclusión principal

LightGBM fue el mejor de los cuatro modelos por F1 en validación cruzada. En test obtuvo **F1 = 0,642** y **AP = 0,712**. El ranking identifica **258 de 407 abandonos (63,4%)** concentrando contactos en el **20%** de la cartera.

RECOMENDACIONES ANTES DE UTILIZARLO EN UN BANCO REAL

01

Verificar datos

Confirmar fuente, licencia, fechas y momento de cada predictor.

02

Validar en el tiempo

Probar el ranking con nuevos períodos y revisar diferencias por segmentos.

03

Medir retención real

Diseñar un piloto A/B con resultados y costos de campaña.

REPRODUCIBILIDAD Y MATERIALES

Colab: Entrega Final TP Diplomatura Data Science.ipynb · **Datos:** Churn Modeling.csv · **Apoyo:** README del Grupo 53.
Fuentes del trabajo: preentrega del 21/09/2026, devolución docente, consigna UTN Unidad 9 y notebook ejecutado. Dataset referido como “Churn Modeling” de Kaggle; URL y licencia primaria pendientes de verificar. La consigna requiere publicación del código y README en un repositorio público de GitHub.